

项目说明

项目一：系统发育树中的单系群自动判定

一句话概括本项目：编写一个程序，读取系统发育树文件，自动判断给定的一组样本（例如 A1-A10）在树上是否构成单系群，并进一步统计严格判定与宽松判定下的比例。

一、为什么要做这个项目

在系统发育分析、群体关系分析和物种分类研究中，研究者经常会问一个非常直接的问题：某一组样本是否稳定地聚在一起？如果一组样本在树上能够对应于某一个内部节点下的全部叶节点，并且该节点下不包含其他组样本，则可判定该组样本在该树上构成单系群。这个项目的目标，就是把这个原本需要人工看图判断的问题，转化为一个可以批量自动完成的程序任务。

这个任务在真实研究中是有意义的。例如，在重复抽样建树、bootstrap 树、基因树集合或不同方法得到的多棵树中，研究者往往希望统计“某一组样本形成单系群的比例”。手工逐棵查看效率低且容易出错，因此很适合用程序来完成。

二、需要先理解的几个基本概念

1. 系统发育树 (phylogenetic tree)

系统发育树是用于表示样本、类群或序列之间系统发育关系的树状图。在本项目中，可将其理解为一种层级化的数据结构：树的末端对应输入样本，分支连接关系反映样本在树拓扑结构中的相对关系。对于本项目，你不需要预先掌握完整的系统发育推断理论，但需要理解树能够表达“哪些样本先聚为一支，以及哪些样本共享更近的共同祖先”。

2. 叶 (leaf / tip) 与内部节点 (internal node)

叶节点是树最末端的样本名称，例如 A1、A2、B7、C。内部节点是连接多个分支的位置，可以理解为一个更大子树的起点。在程序处理中，叶节点通常对应具体的样本标签，内部节点则对应一个可以继续向下遍历的分支结构。

3. 子树 (subtree)

子树是指从某个内部节点出发，向下包含其全部叶节点的一部分树结构。判断单系群时，本质上就是检查：是否存在某个内部节点，使该节点下的全部叶节点恰好对应我们关心的那一组样本。

4. 外类群 (outgroup)

外类群是一个用于辅助定根或提供参照的样本。本项目中用 C 作为外类群。你不一定需要在程序中专门处理外类群，但需要知道它通常不属于 A 组或 B 组。在理解树结构时，可以把它看作相对于研究对象更远的参照样本。

三、什么叫“单系群”

对于本项目，我们采用一个程序化、可操作的定义：

- 如果存在某个内部节点，使其下游全部叶节点恰好为 A1–A10，那么 A 组在这棵树上构成单系群。
- 如果 A 组样本被其他样本打散，例如 A1、A2、A3 与部分 B 组混在一起，或者必须用多个不相连的分支才能覆盖全部 A 组样本，那么 A 组不构成严格意义上的单系群。

你可以把它理解为：A 组样本能否在树上被某一个完整分支唯一对应，并且这个分支中不混入不属于 A 组的其他样本。

四、树文件的基本格式：Newick

大多数程序输出的树文件并不是图片，而是文本格式。最常见的一种格式叫 Newick。它使用括号来表示层级关系，逗号表示并列，分号表示结束。

示例 1： ((A1,A2),(B1,B2),C);

示例 2： (((A1,A2),(A3,A4)),((B1,B2),C));

- 最内层括号表示最先聚在一起的一组样本。
- 括号可以一层一层嵌套，因此整棵树本质上是一个递归结构。
- 有些树文件还会带分支长度，例如 A1:0.02，B1:0.15。本项目基础版可以先忽略分支长度，只关注树的拓扑结构。




图 1 示例 1 对应的树形以及 Newick 文件

五、本项目需要完成的核心任务

1. 读入一棵或多棵 Newick 树文件。
2. 给定目标样本集合，例如 A1-A10。
3. 在每棵树中判断该目标集合是否构成严格单系群并输出原因。
4. 进一步实现一个“宽松判定”版本。例如允许 A 组中最多 1-2 个样本没有聚进目标分支，但其余样本仍形成一个较完整的独立分支。
5. 根据判别结果，统计严格判定通过的比例、宽松判定通过的比例，以及哪些样本最容易成为“破坏单系”的异常样本。

六、建议实现的两个判定标准

判定类型	定义	适用场景
严格判定	存在一个内部节点，其下游全部叶节点构成的集合与目标集合完全相同。	标准版、最基础版实现。
宽松判定	允许目标集合中最多 k 个样本未被包含，但该内部节点下不允许包含任何非目标样本；k 可设为 1 或 2。	处理少量异常样本、边界样本或不稳定树形。

宽松判定不是随意放松标准，而是把“少数异常样本”与“整体不单系”区分开来。程序中请明确写清楚你的宽松规则，例如：允许缺失 1 个或 2 个 A 组样本，但不允许混入任何 B 组样本；或者允许少量混入但要给出明确阈值。只要规则写得清楚、实现一致即可。




图 2 对于 A 组几种不同判别情况及对应树形

七、输入与输出

建议输入

- `tree_file`: 一个包含一棵或多棵 Newick 树的文本文件。
- `target_group`: 目标样本列表, 例如 `[A1, A2, ..., A10]`。
- `tolerance_k`: 宽松判定允许缺失的样本数, 例如 1 或 2。

建议输出

- 每棵树的判定结果: `strict = yes/no`, `tolerant = yes/no`。
- 若未通过 `strict`, 输出原因, 例如: “不存在叶节点集合与目标集合完全一致的内部节点”、“目标样本被分散在多个分支中”或“包含全部目标样本的节点中混入了非目标样本”。
- 若输入多棵树, 统计 `strict` 比例、`tolerant` 比例, 并汇总最常导致失败的样本。

八、进一步思考的扩展问题

- 除了判断 A 组, 是否也可以同时判断 B 组?
- 如果样本数增加到几十或上百, 程序性能如何优化?
- 是否可以把“最容易导致不单系的样本”自动找出来?
- 是否可以把结果做成图表, 例如柱状图或统计表?