

项目说明

项目二：基于测序数据的叶绿体基因组组装、注释与系统发育分析

一句话概括本项目：下载若干杨属和柳属物种的公开测序数据，组装并注释叶绿体基因组，再基于叶绿体序列构建系统发育树，并解释主要拓扑关系。

一、为什么要做这个项目

叶绿体基因组是植物系统发育研究中最常用的数据类型之一。它通常长度适中、结构相对保守、拷贝数较高，因此即使原始数据来自全基因组重测序，也常常能够从中组装出完整或近完整的叶绿体基因组。基于叶绿体基因组开展属内和属间系统发育分析，是植物比较基因组和系统分类研究中的常见思路。

本项目的目标，不是只让大家单独运行某一个软件，而是让大家完成一条较完整的生物信息学分析流程：从公开数据库下载原始数据，完成叶绿体基因组组装与注释，再基于这些结果进行多序列比对和系统发育树构建。

二、在开始之前需要明确的几个问题

1. 本项目处理的是公开原始测序数据，而不是现成的叶绿体基因组。

数据库下载的通常是全基因组测序 reads，其中既包含核基因组 reads，也包含一部分来自叶绿体的 reads。本项目的目标不是完成整个核基因组组装，而是从这些原始数据中组装叶绿体基因组，并基于叶绿体序列开展后续分析。

2. 本项目更关注分析流程是否合理，而不是所有人得到完全一致的答案。

对于同一批原始数据，不同软件、不同参数以及不同参考策略可能得到略有差异的结果。因

此，本项目重点考察的是：流程是否清楚、参数是否有依据、结果解释是否合理，而不是是否与其他人逐位点完全一致。

3. **组装只是中间步骤，不是项目终点。**

叶绿体基因组组装完成后，还需要进一步进行注释、序列整理、多序列比对和系统发育树构建。也就是说，本项目的最终目标不是“拼出一条序列”本身，而是利用这些序列回答物种之间的系统发育关系问题。

4. **外类群的设置是为了帮助建树解释。**

除了 6 个目标物种外，本项目还加入 1 个外类群。外类群的主要作用是提供参照，并帮助理解目标类群之间的分支关系和树的定根方向。在解释结果时，不能只看目标物种彼此是否聚在一起，也要关注外类群位置是否合理。

5. **整个项目是一条前后连贯的流程。**

如果组装结果长度明显异常，后续注释和建树也可能受到影响；如果注释结果不完整，可能说明组装本身存在问题；如果树拓扑明显异常，也应回头检查组装质量、比对质量和外类群设置是否合理。因此，不能把各步骤看成彼此独立的任务。

三、本项目使用的数据

为保证项目能够顺利落地，本项目推荐采用的数据组合：2 个杨属物种、4 个柳属物种，以及 1 个外类群。所有数据均来自公开数据库，均可通过 accession 直接下载。

类别	物种	Run accession	NCBI SRA 链接
杨属	<i>Populus cathayana</i>	SRR13324544	https://www.ncbi.nlm.nih.gov/sra/SRX9751771
杨属	<i>Populus euphratica</i>	SRR13324572	https://www.ncbi.nlm.nih.gov/sra?term=SRR13324572
柳属	<i>Salix brachista</i>	SRR7341535	https://www.ncbi.nlm.nih.gov/sra?term=SRR7341535
柳属	<i>Salix dunnii</i>	SRR12893418	https://www.ncbi.nlm.nih.gov/sra?term=SRR12893418
柳属	<i>Salix purpurea</i>	SRR35181806	https://www.ncbi.nlm.nih.gov/sra?term=SRR35181806

柳属	<i>Salix suchowensis</i>	SRR10197854	https://www.ncbi.nlm.nih.gov/sra?term=SRR10197854
外类群	<i>Arabidopsis thaliana</i>	SRR14460963	https://www.ncbi.nlm.nih.gov/sra/SRX10811117

说明：以上链接均为对应 accession 在 NCBI SRA 中的查询页面。下载前，建议先在网页端确认每个样本的测序平台、数据量和 layout，再使用命令行工具批量下载，如果某个样品数据出现问题，可以搜索同物种其他二代测序数据代替。

四、本项目需要完成的核心任务

1. 下载指定物种的公开原始测序数据。
2. 对原始 reads 进行基本质量控制。
3. 从测序数据中组装叶绿体基因组。
4. 对组装结果进行叶绿体基因组注释。
5. 整理 6 个目标物种和 1 个外类群的叶绿体序列，完成多序列比对。
6. 基于比对结果构建系统发育树。
7. 对树的主要拓扑关系进行解释，并形成一份简洁、清楚、可复现的分析报告。

五、建议分析流程（可参考推荐软件）

这里只提供思路与常用软件，具体软件流程与使用方法自行查询

第一步：下载原始数据

- SRA Toolkit：最常用的命令行下载工具，建议掌握 prefetch 与 fasterq-dump 的基本用法。
- NCBI SRA 网页端：适合先人工核对样本信息、平台类型、数据量和 library layout。

建议至少记录每个物种对应的 accession、下载命令、下载时间以及原始 FASTQ 文件名称。

第二步：原始数据质控

叶绿体组装所需数据量较低，为了方便运行与减少运算资源，可以考虑提取 fa.gz 文件的 100 万行进行后续流程，如效果不好再追加数据。

- FastQC：用于查看原始 reads 的质量报告。
- fastp：可同时完成接头去除、质量过滤和基础统计，适合作为教学项目的主力工具。

- Trimmomatic：经典的 Illumina reads 预处理工具，也可以作为备选方案。

这一阶段建议输出 clean reads，并给出质控前后 reads 数量或碱基数量的简单对比。

第三步：叶绿体基因组组装

- GetOrganelle：当前植物细胞器组装中较常用，适合 Illumina 数据下的叶绿体组装。
- NOVOPlasty：基于 seed-and-extend 思路的细胞器组装工具，也常用于叶绿体组装。
- Bandage：若需要查看组装图或检查是否形成单一环状结构，可用于辅助观察 assembly graph。

组装阶段至少需要说明：采用了哪一种工具、使用了哪些关键参数、是否使用了参考或 seed。

第四步：组装结果检查与整理

- minimap2：可将组装结果与参考叶绿体序列进行快速比对，检查长度和整体一致性。
- Bandage：用于观察组装图是否存在断裂、重复或结构歧义。
- OGDRAW：可辅助检查 IR、LSC、SSC 等区域的基本布局，并输出规范图形。

如果组装结果异常短、异常长或明显不完整，应先回到组装阶段检查，而不是直接进入建树。

第五步：叶绿体基因组注释

- GeSeq：网页端方便，适合教学场景下完成基础叶绿体注释。
- PGA (Plastid Genome Annotator)：命令行工具，适合批量处理多个样本。
- OGDRAW：可在注释完成后绘制叶绿体基因组结构图。

注释阶段至少需要给出蛋白编码基因、tRNA、rRNA 的基本统计，并尽可能识别 IR、LSC 和 SSC 结构。

第六步：多序列比对（比对与建树可自行选择全基因组建树、单拷贝基因建树，方法可选择溯祖法、串联法等）

- MAFFT：常用且稳定，适合多条叶绿体基因组序列的整体比对。
- MEGA X：界面友好，适合查看比对结果、整理序列和导出文件。

若整条叶绿体基因组比对困难，也可以先提取共享序列区段或共享基因集合，再进行比对。

第七步：系统发育树构建

- IQ-TREE 2：适合最大似然建树，支持模型选择和 bootstrap。
- RAxML-NG：常用的最大似然建树工具，也适合标准命令行流程。

- MEGA X: 侧重可视化，也可以完成较基础的建树分析。

最终结果至少应包含 1 棵带物种标签的树，并明确指出外类群位置、杨属关系和柳属关系。

六、建议回答的核心问题

- 这些公开原始数据是否都能够支持叶绿体基因组组装？
- 组装出的叶绿体基因组长度和注释结果是否大体合理？
- 杨属物种是否倾向于聚成一支，柳属物种是否倾向于聚成一支？
- 外类群是否位于杨属和柳属之外，并起到定根作用？
- 如果树形结果与你的直观预期不完全一致，可能的原因是什么？

七、项目的最低要求与提高要求

最低要求	提高要求
• 成功下载全部指定数据。	• 全部 6 个目标物种和 1 个外类群都成功纳入分析。
• 至少完成 4 个以上样本的叶绿体组装。	• 组装结果结构较完整，注释较规范。
• 至少完成 1 轮注释和 1 棵系统发育树。	• 树包含 bootstrap 支持度，并能给出较清楚的解释。
• 报告中能够清楚说明主要步骤和主要结果。	• 能够比较不同软件或不同参数下的结果差异，流程脚本化程度较高。

八、进一步思考的扩展问题

- 是否可以比较 GetOrganelle 与 NOVOPlasty 的组装结果差异？
- 是否可以只提取叶绿体共享蛋白编码基因再建树，并比较与整叶绿体序列建树结果的差异？
- 如果某个样本组装失败，原因更可能来自数据质量、覆盖不足还是参数设置？
- 是否可以进一步比较杨属与柳属叶绿体基因组在长度、基因数或 IR 区域上的差异？